

Reproduction: Stealing ML Models via Prediction APIs

Python 3 本地黑盒 oracle 复现

Model-Stealing-Reproduce-Pre

复现目标：不是跑旧代码，而是复现攻击机制


本地黑盒设置

- 本地训练受害者模型 f
- 攻击者只能访问 query API
- 不读取模型参数、不访问训练集
- 得到副本 $f' \approx f$

为什么这样复现？

原仓库是 Python 2 + 旧 sklearn + Theano + AWS/BigML wrapper。

我们把论文核心攻击抽象成 Python 3 的本地 oracle，便于讲解和现场演示。



复现实验总览：数据集、模型、攻击接口

Phase	数据集	受害者模型	攻击接口
Binary LR	Breast Cancer	Logistic Regression	query_proba
Multiclass LR	Iris / Digits	Softmax / OvR LR	query_proba
Rounding	Digits	Softmax / OvR LR	rounded query_proba
Decision Tree	Iris	DecisionTree(max_depth=3)	query_leaf_id
Label-Only	Digits	Softmax LR	query_label
KLR leakage	Digits	RBF representer model	extracted white-box params

统一评估


- **Test agreement:** 测试集上 $f'(x) = f(x)$ 的比例
- **Uniform agreement:** 在 $[-1, 1]^d$ 均匀采样点上的一致率
- **TV distance:** 比较概率分布时使用 total variation distance

二元 Logistic Regression

$$p = \sigma(w^\top x + b)$$

$$\log \frac{p}{1-p} = w^\top x + b$$

- Breast Cancer: $d = 30$
- 未知数: $w_1, \dots, w_{30}, b$
- 查询 $d + 1 = 31$ 个线性无关点
- 解线性系统 $[X, 1]\theta = \text{logit}(p)$




Equation-Solving 结果: 约 1 query / parameter 即可

模型	参数	查询	Test	Uniform
Binary LR	31	31	100%	100%
Iris softmax	15	15	100%	100%
Digits softmax	650	650	100%	100%
Digits OvR	650	650	100%	100%

讲解重点

Digits softmax 的 650 次查询, 对应论文 Amazon Digits 案例的量级。这里用本地 oracle 复现了同样的核心现象。




Rounding 防御：小数位数少了，攻击才明显变难

小数位	查询	Test	Uniform
5	650	100.00%	99.97%
4	650	100.00%	99.96%
3	650	100.00%	99.90%
2	650	99.63%	99.09%

结论

4-5 位 confidence 基本挡不住；2-3 位会明显增加概率误差，但仍不是完整防御。



Decision Tree: leaf id 是路径“身份证”


攻击步骤

- 1 查询一个点，得到 leaf id
- 2 逐个改变特征值
- 3 leaf id 变化 $\Rightarrow$ 路径在该特征上分裂
- 4 连续特征二分搜索阈值

指标	数值
----	----

Dataset	Iris
Target leaves	5
Extracted leaves	5
Queries	557
Test agreement	100%
Uniform agreement	100%

Target sklearn tree



Extracted leaf intervals

```
leaf 1 -> class 0
x3: [-1.00, -0.42]

leaf 4 -> class 1
x2: [-1.00, 0.34]; x3: [-0.42, 0.38]

leaf 5 -> class 1
x2: [0.34, 1.00]; x3: [-0.42, 0.38]

leaf 7 -> class 2
x3: [0.38, 1.00]


leaf 8 -> class 2
all features
```

Label-Only: 去掉 confidence 后, 成本显著上升

方法	查询	Uniform agreement
confidence solve	650	100.00%
label uniform	650	68.83%
label adaptive	650	76.13%
label adaptive	6,500	97.83%
label adaptive	26,000	99.33%

讲解重点

只返回 label 能有效抬高攻击成本; 但主动学习式 retraining 仍能逐步逼近目标模型。



教学版 representer model

$$s_c(x) = \sum_{r: y_r=c} \exp(-\gamma \|x - r\|^2)$$

- Digits 数据集
- 每类 5 个 representer
- 总计 50 张训练图像
- 提取白盒模型 $\Rightarrow$ representer 矩阵泄露

要传达的风险

模型窃取不只偷走功能，也可能带走训练数据子集。

Loaded KLR representer: training images embedded in the extracted model



复现踩坑：这些可以作为组会补充

工程环境

- 原仓库：Python 2 + Theano + 旧 sklearn
- 新环境：Python 3.14 + sklearn 1.8
- sklearn 移除了 multi_class 参数
- 解决：softmax 用新版默认 LR, OvR 显式套 OneVsRestClassifier

本机环境

- Arch/PEP 668 禁止系统 pip 安装
- 使用 `python -m venv .venv`
- 用户级 `distutils-precedence.pth` 警告不影响运行

算法实现

- 决策树不能只看区间两端 leaf id
- 可能出现“两端同叶，中间另有叶”
- 连续阈值有 $\leq / >$ 边界问题
- 最终按“当前叶子的路径谓词”逐特征恢复

汇报时的表述

这次复现是“重写核心机制”，不是“跑通旧仓库”：算法思想稳定，但工程依赖和 API 会随时间变化。

我们复现到的核心结论

- Confidence values 让 LR 提取从学习问题变成解方程问题
- 对多类 LR, 约 1 query / parameter 即可达到近似完美一致
- Decision tree 可利用 leaf identity 做路径查找
- Label-only 能提高成本, 但不能根除提取
- Kernel representer 模型存在训练数据泄露风险

当前复现限制

未复跑 AWS/BigML 在线实验; 决策树和 KLR 是教学版; MLP、Lowd-Meek 完整实现可作为后续扩展。